

به نام خدا

غزاله کریمی ۴۰۲۱۰۶۳۷۲
۴۰۳۱۰۰۴۰۵ مهشید بارگاهی

۱ بارگذاری داده‌ها (ETL) و پر کردن جداول پایگاهداده

در این بخش از پروژه، داده‌ها از جداول products، products_properties و bdbkala_full (مانند staging) به جداول اصلی پایگاهداده منتقل شدند. هدف، تبدیل دیتاست خام به ساختار نرم‌الشده و سازگار با قیود (Constraints) و قواعد تجاری بود. همچنین برای جلوگیری از توقف فرآیند در صورت وجود داده‌های نامعتبر، مکانیزم ثبت خطا در سطح ETL پیاده‌سازی شد.

۱.۱ زیرساخت ثبت خطا (Logging) Error (ETL)

ابتدا جدول etl_error_log برای ذخیره خطاها رخداده در فرآیند بارگذاری ساخته شد. این جدول شامل اطلاعاتی مانند نام جدول مقصد، نوع عملیات، نام قید (در صورت وجود)، SQLSTATE، پیام خطا و داده‌ی همان رکورد به صورت JSONB است. سپس تابع log_etl_error() ایجاد شد تا در تمام مراحل بارگذاری، هر خطا به صورت یکپارچه ثبت شود و عملیات ادامه پیدا کند.

۲.۱ پر کردن جداول پایه با run_staging_load()

یک رووال (Procedure) جهت پر کردن جداول پایه پیاده‌سازی شد تا وابستگی‌های کلیدی و ارجاعی (FK) رعایت شوند. ترتیب اجرای این مرحله به صورت زیر بود:

self-
products_properties: ابتدا دسته‌های ریشه از products_properties وارد شدند. سپس زیردسته‌ها به صورت referencing با فیلد parent_category_id اضافه شدند.

branch_manager: مدیران شعب از branch_product_suppliers استخراج و در جدول ذخیره شدند.

address: سه نوع آدرس وارد شد:

۱. آدرس‌های ارسال سفارش از bdbkala_full (همراه با city/region/zip)
۲. آدرس شعب از branch_product_suppliers (با مقادیر NULL برای شهر/منطقه/کدپستی)
۳. آدرس تامین‌کنندگان از branch_product_suppliers (با مقادیر NULL برای شهر/منطقه/کدپستی)

branch: شعب با اتصال به address و branch_manager ایجاد شدند تا FK‌ها برقرار باشند.

supplier: تامین‌کنندگان وارد شدند و در صورت وجود آدرس، address_id نیز به رکورد متصل شد.

در تمامی مراحل فوق، در صورت رخداد هرگونه خطا یا نقض constraint، اطلاعات رکورد و خطا در etl_error_log ثبت شد.

۳.۱ پر کردن جدول Customer با اعتبارسنجی

برای مشتری‌ها، علاوه بر درج داده‌ها، عملیات اعتبارسنجی انجام شد:

- تابع normalize_phone_us_e164 برای نرمال‌سازی شماره تلفن پیاده‌سازی شد.
- رکوردهای نامعتبر (ایمیل نامعتبر، تلفن نامعتبر، نام خالی) در جدول customer_reject_log ذخیره شدند.
- تنها رکوردهای معتبر وارد جدول customer شدند.
- فیلدهای customer_segment، customer_status، customer_type و income تولید شدند.

۴.۱ پر کردن جدول Product

در این مرحله، داده‌های محصولات از products_properties وارد جدول product شدند:

- از فیلد attributes از JSONB به specifications تبدیل شد.
- محصول از طریق category_id و زیردسته‌ی متناظر تعیین شد.
- تولید شد تا vat_exemption_percent (براساس product_name) به صورت deterministic (hashtext(product_name)) باشد.

۵.۱ پر کردن جدول Branch_Product

این جدول رابطه‌ی بین شعب و محصولات را نگهداری می‌کند:

- ارتباط محصول و شعبه از branch_product_suppliers استخراج شد.
- با استفاده از میانگین sale_price در bdbkala_full_unit_price محاسبه شد و در صورت نبود، از فرمول $1.30 * \text{استفاده شد}$.
- از میانگین تخفیف‌ها استخراج شد (در غیر این صورت 0).

۶.۱ پر کردن جدول Supply

:Branch_Product و Supplier پس از آماده شدن

- برای هر (supplier, branch_product) supply رکورد ایجاد شد.
- از cost_price و lead_time_days از supply_time برداشت شد.

۷.۱ پر کردن جدول Wallet

موجودی کیف پول از جدول wallet_balances به جدول wallet متنقل شد. برای جلوگیری از درج تکراری، از ON CONFLICT DO UPDATE استفاده شد تا در صورت وجود رکورد قبلی، مقدار balance بروزرسانی گردد.

۸.۱ پر کردن جدول **Ordere** با داده‌های تاریخی

به دلیل وجود تریگرهایی که درج داده‌ی تاریخی را محدود می‌کردند (مانند الزام `order_date = CURRENT_DATE`، تریگرهای مربوطه موقتاً غیرفعال شدند. سپس:

- `customer_id` با اولویت `email > phone > name` تعیین شد.
 - تاریخ `order_date` با پشتیبانی از چند قالب (مانند `YYYY-MM-DD` و `MM.DD.YYYY`) تبدیل شد.
 - مقادیر `priority/status/payment_method` مانند `enum` به مقادیر مجاز نگاشت شدند.
- در نهایت تریگرهای مجدداً فعال شدند.

۹.۱ پر کردن جدول **Order_Item** با داده‌های تاریخی

برای `order_item` نیز به دلیل تریگرهای قیمت‌گذاری، عملیات درج تاریخی با غیرفعال‌سازی موقت تریگرهای BEFORE INSERT انجام شد. سپس:

- مقدار `quantity` قبل از تبدیل نوع (cast) اعتبارسنجی شد تا مواردی مثل 1- یا 1.0- باعث توقف فرآیند نشوند.
- اتصال به `branch_product_suppliers_staging` با استفاده از `branch_product` انجام شد تا انتخاب شعبه دقیق باشد.
- خطاهای هر رکورد در `log_error` ثبت شدند و فرآیند ادامه یافت.

۱۰.۱ پر کردن جدول **Feedback**

با ذخوردها با اتصال `reviews` به اطلاعات محصول و سپس `branch_product` تولید شدند. قیود مربوط به امتیاز (۱۰ تا ۵) و طول کامنت بررسی شد و در صورت نقض، رکورد در `log_error` ذخیره شد.

۱۱.۱ پر کردن جدول **Shipment**

برای `shipment`، تاریخ‌ها دارای قالب‌های مختلف بودند؛ بنابراین تاریخ‌ها با `to_date` `regex` تشخیص و با `date` تبدیل شدند. همچنین `filed` `packaging` تحلیل شد تا نوع/سایز/جنس بسته‌بندی استخراج گردد. هرگونه نقض قید (مانند قوانین حمل و نقل و بسته‌بندی) در `log_error` ثبت شد.

۱۲.۱ جمع‌بندی

در این بخش، بارگذاری داده‌ها از `staging` به جداول اصلی با رعایت ترتیب وابستگی‌ها انجام شد. داده‌ها پاکسازی و استاندارد شدند و برای داده‌های تاریخی، تریگرهای محدودکننده به صورت موقت غیرفعال شدند. همچنین با ثبت خطاهای `ETL`، فرآیند `ETL` بدون توقف اجرا شد و رکوردهای مشکل دار برای بررسی و اصلاح بعدی نگهداری شدند.

۲ تولید داده‌های مصنوعی (Synthetic Data Generation)

در این بخش، به منظور تست سناریوهای واقعی تر سیستم (وفداداری مشتریان، خرید با BNPL تراکنش‌های کیف‌پول و فرآیند مرجعی)، مجموعه‌ای از داده‌های مصنوعی روی دیتابیس تولید شد. هدف این بود که بدون تغییر ساختار داده‌ها یا قوانین تجاری، رکوردهای جدیدی ایجاد شوند که برای تحلیل، گزارش‌گیری و ارزیابی عملکرد تریگرهای و قیود مناسب باشند.

۱.۲ تعیین محدوده داده‌های جدید

ابتدا بیشترین order_id موجود در جدول ordere استخراج شد تا محدوده سفارش‌های جدید مشخص شود:

- SELECT MAX(order_id) FROM ordere;

- خروجی: 25260

در نتیجه، تمامی سفارش‌های تولیدشده در این مرحله order_id بزرگ‌تر از مقدار فوق هستند و در زمان خروجی گرفتن CSV نیز از همین مرز برای فیلتر استفاده شد.

۲.۱ محاسبه وفاداری (Loyalty) مشتریان

برای محاسبه امتیاز وفاداری، خریدهای سه ماه اخیر مشتریان در نظر گرفته شد:

- مبلغ خرید سه ماه اخیر هر مشتری: $\text{SUM}(\text{quantity} * \text{final_price_at_order_time})$
- تبدیل به امتیاز وفاداری: $\text{FLOOR}(\text{total}/100)$

سپس مشتریانی که $\text{points_3m} > 0$ داشتند به عنوان مشتریان واجد شرایط Customers (Eligible) انتخاب شدند.

۳.۱ افزایش امتیاز وفاداری با سفارش‌های تصادفی

برای افزایش مصنوعی امتیاز وفاداری برخی مشتریان، ابتدا یک جدول موقت target_boost ساخته شد که شامل ۴۰۰ مشتری تصادفی بود. این مشتری‌ها طوری انتخاب شدند که سابقه BNPL نداشته باشند تا سناریوی BNPL بعدی با کمترین تداخل انجام شود.

۱.۳.۱ ایجاد سفارش‌های جدید در ۴۵ روز اخیر

برای هر مشتری در target_boost، سه سفارش جدید با ویژگی‌های زیر ایجاد شد:

- status = 'Received'
- priority = 'High'
- payment_method = 'In-App Wallet'

به صورت تصادفی در بازه ۴۵ روز اخیر order_date

از آنجا که تریگر trg_enforce_order_date درج سفارش با تاریخ غیر از امروز را محدود می‌کرد، این تریگر به صورت موقت غیرفعال و پس از درج سفارش‌ها مجدداً فعال شد.

۱.۳.۲ ایجاد آیتم‌های سفارش Items (Order)

پس از ایجاد سفارش‌ها، برای هر سفارش تعدادی آیتم سفارش ساخته شد:

- انتخاب محصول از میان ۲۰ محصول گران‌تر (برای افزایش مبلغ خرید و امتیاز وفاداری)
- تعداد هر آیتم به صورت تصادفی در بازه ۳ تا ۵
- return_status = NULL

۴.۲ ایجاد سفارش‌های BNPL برای مشتریان واجد شرایط

پس از افزایش فعالیت مشتریان، برای مشتریانی که امتیاز وفاداری آنها مثبت بود ($points_3m > 0$) سفارش‌هایی با روش پرداخت BNPL ایجاد شد:

payment_method = 'BNPL' •

order_date = CURRENT_DATE •

status = 'Received' •

priority = 'High' •

۱.۴.۲ ایجاد آیتم سفارش برای سفارش‌های BNPL

برای هر سفارش، یک آیتم سفارش ایجاد شد:

quantity = 1 •

• انتخاب محصول ارزان‌تر (برای کاهش ریسک بدھی BNPL)

۵.۲ ایجاد Plan BNPL برای سفارش‌های BNPL

برای تمامی سفارش‌هایی که روش پرداخت آنها BNPL و تاریخ آنها امروز بود، یک رکورد در جدول bnpl_plan ایجاد شد و وضعیت آن Active تنظیم گردید.

۶.۲ شبیه‌سازی بازپرداخت اقساطی (Repayment) از طریق کیف‌پول

برای طبیعی‌تر شدن داده‌های BNPL فرآیند بازپرداخت اقساط به صورت زیر شبیه‌سازی شد:

۱. محاسبه مبلغ کل بدھی هر BNPL از روی order_item

۲. تعیین تصادفی تعداد اقساط پرداخت شده paid_installments (paid بين ۰ تا ۳)

۳. تولید اقساط با generate_series(1,3) تا سقف تعداد پرداخت شده

۴. ایجاد Payment از نوع wallet_transaction برای هر قسط

۵. ایجاد رکوردهای repayment با اتصال به wallet_id و transaction_sequence_number (طبق constrain-transaction-repayment) های موجود)

این روند باعث شد داده‌های پرداخت BNPL هم با قیود بانک اطلاعاتی سازگار باشد و هم رفتار واقعی‌تری را شبیه‌سازی کند.

۷.۲ ایجاد تراکنش‌های پرداخت برای سفارش‌های Wallet

برای سفارش‌هایی که روش پرداخت آنها In-App Wallet بود، تراکنش پرداخت ایجاد شد:

• مبلغ تراکنش برابر مجموع مبلغ آیتم‌های سفارش

• زمان تراکنش نزدیک به تاریخ سفارش (۱ یا ۲ روز قبل به صورت تصادفی)

۸.۲ ایجاد تراکنش برداشت (Withdrawal)

برای شبیه‌سازی برداشت از کیف پول:

- کیف‌پول‌هایی با $balance > 50$ انتخاب شدند.
- حدود ۳۰٪ از آنها به صورت تصادفی انتخاب شدند.
- برای آنها تراکنش Withdrawal با مبلغی بین ۱۰٪ تا ۴۰٪ موجودی ایجاد شد.

۹.۲ ایجاد تراکنش واریز (Deposit) برای سازگاری با موجودی نهایی

از آنجا که wallet.balance موجودی نهایی را نگه می‌دارد، لازم بود ledger تراکنش‌ها با آن سازگار شود. بنابراین:

- مجموع پرداخت‌ها و برداشت‌ها به عنوان total_out محاسبه شد.
- اگر $balance - total_out > total_out$ (balance - total_out) ایجاد شد.

۱۰.۲ تولید درخواست‌های مرجوعی (Return Request)

برای شبیه‌سازی فرآیند مرجوعی:

- ۵۰۰ آیتم سفارش تصادفی انتخاب شد که سفارش آنها حتماً Received باشد.
- دلیل مرجوعی به صورت تصادفی از Damaged / Wrong Item / Late Delivery
- نتیجه بررسی به صورت تصادفی از Return Pending Review / Return Approved / Return Rejected
- order_date چند روز بعد از request_date
- با احتمال ۷۰٪ مقداردهی شد و در غیر این صورت NULL باقی ماند.

۱۱.۲ خروجی CSV از داده‌های تولیدشده

در پایان، داده‌های تولیدشده برای ارائه و تحلیل به صورت CSV خروجی گرفته شدند. خروجی‌گیری با ابزار گرافیکی انجام شد و فیلترهایی مانند order_id > 25260 برای انتخاب فقط رکوردهای جدید در نظر گرفته شد.

۱۲.۲ جمع‌بندی

در مجموع، این بخش با تولید داده‌های مصنوعی کنترل شده، سناریوهای کلیدی سیستم را پوشش داد: افزایش وفاداری مشتریان، ایجاد سفارش‌های BNPL و بازپرداخت اقساط، ساخت تراکنش‌های کیف‌پول و همچنین شبیه‌سازی فرآیند مرجوعی. تمام داده‌ها به گونه‌ای تولید شدند که با قیود و روابط پایگاهداده سازگار بوده و برای تحلیل و تست قابل استفاده باشند.